SK 네트웍스 Family AI 33기 : 1팀

수집 데이터 보고서

산출물 단계	데이터 수집 및 저장
제출 일자	2026. 10. 08. (제출 예정)
깃허브 경로	https://github.com/20260528-skn-family-ai-33/SKN33-Final-1Team
작성 팀원	최지흠

수집 데이터

1. 수집 데이터 개요

- 2026년 10월 7일 기준, 재설계한 포스터 검수 워크플로우(v3: 정보 검수·시각 검수 두 에이전트, MCP 기반)의 개발용 자료를 정리한다. 확보: 전국문화축제표준데이터 1,364건, 샘플 포스터 1장, 가상 발주 3건(합성), 검수 스키마 초안. 수집 예정: 서울문화포털 샘플 포스터, 표준데이터 OpenAPI 호출. 사람 검토는 모두 대기 중이며, 이전 방향(광고 납품 검수) 자료는 이번 집계에서 제외한다.

데이터명	수집 대상	수집 목적	사용 예정 기능	출처 / 저작권
전국문화축제표준데이터	전국 문화축제 1,364건(18필드): 행사명·기간·장소·주최/주관/후원·연락처·주소·좌표	행사명·일시·장소·연락처의 공식 근거 확보, 합성 포스터의 현실적 내용 재료	정보 검수 에이전트의 근거 검색·날짜 비교, 합성 포스터 입력(제안)	공공데이터포털 15013104, 한국관광공사·지자체 제공. JSON 내려받기 완료(2026-10-07). 이용허락 조건 확인 대기
서울문화포털 샘플 포스터	문화행사 목록의 포스터 이미지와 목록 메타(제목·기간·장소·요금·분류)	실제 포스터로 OCR·요소 추출과 시각 검수 개발·평가	OCR·요소 추출, 시각 검수 에이전트, 정답 라벨 작성	서울문화포털 (culture.seoul.go.kr). 수집 예정, 현재 0장. 사이트에 저작권 표기가 있어 약관·robots.txt 확인 후 내부 개발용 소량만
샘플 포스터 1장	김천김밥축제 포스터(800×1131 WEBP). 검수 요소 38개 라벨 초안	검수 요소·정답 구조 시험, OCR 판독 시험	OCR 시험, 케이스 스키마 검증	제공받은 이미지. 출처 URL 미확인, 권리 확인 대기. 내부 시험용

데이터명	수집 대상	수집 목적	사용 예정 기능	출처 / 저작권
가상 발주 3건 (F&B·페스티벌·가상 인물)	발주 문서 28건(PDF·MD 각 28), 납품 포스터 18장(1080×1350), 증빙 PDF 11개, 정답 JSON 12개	포스터 + 발주서·승인 문안 입력 형태의 개발·시험	기준 구조화, 정보·시각 검수 시험	자체 합성(Python·Pillow). 이미지 폰트 Noto KR(OFL), PDF 임베드 맑은 고딕은 약관 확인 대기. 로컬 data/virtual-orders(저장소 미반영)
검수 스키마 초안	케이스 스키마 v0.1, 검수 항목 카탈로그 16개, 예시 케이스 2건	입력·기대 출력·정답 구조 정의(확정 전 초안)	앱 공통 결과 계약(check_id, status, evidence, bbox)과 정합	AI 작성(Claude Code), 사람 검토 대기. 로컬 docs-draft/poster-schema
이전 방향 자료 (제외)	광고 납품 검수용 합성 문서·요청·이미지(기존 보고서 집계분)	이전 방향 참고	이번 집계에서 제외, 별도 관리	저장소 data/collection·data/samples에 보존. 기존 보고서 기준 유지

2. 수집 방법 및 자동화 절차

2.1 수집 방식 (해당 항목에 체크)

수집 방식	선택	수집 방식	선택
웹 크롤링	☑	외부 API 직접 호출	☑
사용자 입력 자료 접수	☑	팀 문서 파일 업로드	☐
기타: AI 자체 제작(가상 발주 3건·스키마 초안)	☑	기존 시연 자료 확인	☐

2.2 사용 기술 및 자동화 절차

사용 언어 / 라이브러리	수집·집계: Python 3.12 표준 라이브러리(json, csv, collections, datetime), 이미지 확인 Pillow. 공공데이터: data.go.kr 파일 데이터(JSON) 내려받기, OpenAPI는 활용신청·서비스키 발급 후 호출 예정(상세 조건 미확인). OCR: RapidOCR(PP-OCRv5 한국어, ONNX CPU)로 글자·좌표 추출. 검증: jsonschema 4.26.0. 서울문화포털 샘플 수집 도구: 약관·robots.txt 확인 후 선정(미정).
자동화 여부 및 주기	현재: 표준데이터 JSON을 1회 내려받아 분석 스크립트를 수동 실행했다. 원천 갱신 주기는 분기이다(공공데이터포털 표기). 예정: OpenAPI 호출 자동화는 활용신청 승인 후 구현하고 분기 단위로 재수집한다. 서울문화포털은 샘플 1회 수집이며 정기 수집은 하지 않는다. 체크 항목별 현황: 외부 API(표준데이터)는 파일 확보 완료·OpenAPI 미적용, 웹 크롤링(서울문화포털)은 미착수, 사용자 입력 자료는 샘플 포스터 1장 접수.
오류 발생 시 예외 처리 전략	API: 응답 코드를 확인하고 실패 시 재시도 후 원본 응답을 보존한다. 일일 호출 한도는 활용신청 때 확인한다(현재 미확인). 파일: 레코드 수·필드 수·UTF-8 디코딩을 확인한다. 날짜 순서 오류·중복 등 이상치는 삭제하지 않고 목록(CSV)에 기록한다. 크롤링: robots.txt 불허·접속 실패 페이지는 제외하고 사유를 기록한다. 권리·약관 미확인 자료는 사용 승인 전까지 대기한다.

2.3 예시 스크립트 또는 흐름도 첨부

[수집 및 저장 흐름]

1) 근거 데이터 확보: 공공데이터포털 전국문화축제표준데이터(15013104) JSON 내려받기 → 1,364건·18필드 확인 (완료)

2) 품질 점검: 날짜 형식·순서, 완전 중복, 같은 행사 값 충돌, 좌표·연락처 형식 점검 → 이상치 90행 목록 (완료)

3) 샘플 포스터 확보: 서울문화포털 문화행사 목록의 포스터 이미지와 목록 메타 수집 (예정, 약관·robots.txt 확인 후)

4) 요소 추출·정답 초안: OCR로 글자·좌표 추출 → 검수 요소 JSON·케이스 JSONL 정답 초안 작성 (포스터 1장 시험 완료)

5) 기준 연결(제안): 표준데이터의 행사명·기간·장소·주최·연락처를 근거 검색 대상으로 연결하고, 같은 행사의 후보가 여럿이면 출처·기준일을 함께 보존 (설계 중)

6) 검증·보존: 스키마·정합성 검사(validate_cases.py), 원본·출처·기준일 분리 보관

아키텍처 연결(제안): 표준데이터 = 근거 검색 Tool 대상, 서울문화포털 포스터 = 입력 포스터, 발주서·승인 문안 = Resources(고정 기준), 정답 checks = 앱 공통 결과 계약(check_id, status, evidence, bbox)

실행 경로: docs-draft/poster-schema/validate_cases.py (로컬 초안, 저장소 반영 전)

3. 데이터 설명 및 구성

3.1 파일 및 필드 설명

파일명 / 테이블명	필드명	데이터 타입	설명	예시
전국문화축제 표준데이터.json	fields[].id	string	필드 정의 18개	축제명
전국문화축제 표준데이터.json	records[]	object (1,364개)	축제 1건 = 레코드 1개, 값은 모두 문자열	{"축제명": "김천김밥축제", ...}
전국문화축제 표준데이터.json	축제명 / 개최장소	string	행사명·장소(여러 곳은 "+"로 연결)	김천김밥축제 / 직지문화공원+사명대사공원+친환경생태공원
전국문화축제 표준데이터.json	축제시작일자 / 축제종료일자	string (YYYY-MM-DD)	개최 기간	2026-10-23 / 2026-10-25
전국문화축제 표준데이터.json	축제내용	string	프로그램 요약(중앙값 24자)	로컬 및 8도김밥 판매+공연+체험프로그램 운영 등
전국문화축제 표준데이터.json	주최기관명 / 주관기관명 / 후원기관명	string	기관명(후원은 52.1% 비어 있음)	경상북도 김천시청
전국문화축제 표준데이터.json	전화번호 / 홈페이지주소	string	문의처(각 8.6%·40.0% 비어 있음)	054-420-6714 / https://gimbapcity.kr/main/main.html
전국문화축제 표준데이터.json	소재지도로명주소 / 소재지지번주소 / 위도 / 경도	string	위치(좌표 17.7% 비어 있음)	경상북도 김천시 대항면 직지사길 130 / 36.117093 / 128.0081803
전국문화축제 표준데이터.json	데이터기준일자 / 제공기관코드 / 제공기관명 / 관련정보	string	갱신 기준일·제공기관(페이지 안내 15필드 외 3개), 관련정보는 88.9% 비어 있음	2026-09-03 / 경상북도 김천시
posters/* (서울문화포털, 예정)	픽셀 / 크기	WEBP·PNG·JPEG / integer	입력 포스터 이미지	800×1131 (샘플 1장 기준)
listing-meta (서울문화포털, 예정)	제목 / 기간 / 장소 / 요금(유료·무료) / 분류	string	목록 메타데이터(수집 후 필드 확정)	수집 후 기록

파일명 / 테이블명	필드명	데이터 타입	설명	예시
poster-cases.jsonl	case_id / source.origin	string	케이스 ID·출처 구분(실제·합성·변형). 예시 2건은 poster-cases.example.jsonl	EVT-0001 / real_public
poster-cases.jsonl	input.image (path, width, height, format, sha256)	string / integer	이미지 파일 정보	images/EVT-0001.webp / 800 / 1131
poster-cases.jsonl	gold.extraction.texts[] (id, role, text, bbox, legibility)	string / number[4]	글자 영역·전사·좌표(0~1 비율)	T04 / event_name / 김천김밥축제
poster-cases.jsonl	gold.extraction.fields (event_name, dates, venues, organizers …)	object / null	구조화 정보(없으면 null)와 근거 text_ids	dates.start = 2026-10-23
poster-cases.jsonl	gold.checks[] (check_id, verdict, reason_code, targets, error)	string / array	검사별 판정·이유·위치·오류	DT-01 / pass
poster-cases.jsonl	label_meta (label_status, catalog_version, created_at)	string	라벨 상태(AI 초안 / 사람 검토 / 합의)	draft_ai / 0.1 / 2026-10-07
check-catalog.json	check_id / category / requires_reference / default_severity	string / array	검수 항목 정의 16개(핵심 10·확장 6)	TXT-01 / text / [] / medium
이상치_목록.csv	분류 / 레코드번호 / 축제명 / 사유	string	표준데이터 이상치 90행	날짜 순서 오류 / 1198 / 여수밤바다 불꽃축제
data/virtual-orders/registry.csv	asset_id / case_id / type / path / sha256 / bytes / real_or_synthetic	string / integer	가상 발주 자료 97건 목록(문서·이미지·증빙·정답)	VO-01:VO-01_rfp.pdf / VO-01 / document_pdf

3.2 데이터 양

전체 수집 데이터 건수	전국문화축제표준데이터 1,364건(18필드·24,552개 값, JSON 약 1.0MB). 제공: 지자체 1,299건·한국관광공사 65건. 2026년 시작 798건, 기준일(2026-10-07) 진행 43건·예정 217건. 샘플 포스터 1장(검수 요소 38개). 서울문화포털 샘플은 0장이며

	목표 수량은 미정이다(멘토 초기안: 입력·출력 약 100쌍, 협의). 가상 발주 3건: 문서 28건(PDF·MD 각 28, 총 56파일), 납품 포스터 18장, 증빙 PDF 11개, 정답 JSON 12개(목록 97건). 스키마 초안: 검수 항목 16개, 예시 케이스 2건.
추출된 고품질 데이터 건수 (필터링 후 기준)	표준데이터 자동 필터: 필수 5항목(행사명·장소·시작·종료·주최) 존재 1,364건 → 날짜 순서 정상 1,362건 → 완전 중복 제거 1,338건. 같은 행사 값 충돌 후보 54건(목록 57행 중 3행은 필터에서 제거)을 빼면 1,284건. 진행·예정 행사 중 필터 통과 256건(전화 또는 URL 있음 231건). 사람 검토 통과량: 0건. 모든 정답 라벨은 AI 초안(draft_ai)이며 구조 검사 통과를 정확도나 일반화 성능으로 해석하지 않는다. 학습·성능 평가는 미실행이다.

3.3 저장 위치 및 포맷

저장 경로	저장소: SKN33-Final-1Team (표지 GitHub 경로). 현재 아래 자료는 로컬 작업 폴더에 있으며 저장소 반영 전이다. 표준데이터 JSON: 다운로드 폴더 → data/collection/raw/public/culture-festival/ (예정) 서울문화포털 샘플 포스터: data/collection/raw/posters/seoul-culture/ (예정) 가상 발주: data/virtual-orders/. 스키마·분석: docs-draft/poster-schema/, festival-data-analysis/ (로컬) 이전 방향 자료: data/collection/, data/samples/ (보존, 집계 제외). 보고서: docs/reports/data-collection/
저장 포맷	☑ CSV ☑ JSON ☐ SQLite ☑ 기타: JSONL, WEBP·PNG, PDF, Markdown 원천 표준데이터는 JSON(fields/records 구조), 정답 라벨은 JSONL(한 줄에 케이스 1건), 이상치 목록은 CSV이다.
인코딩	☑ UTF-8 ☐ 기타 JSON·JSONL·Markdown은 UTF-8(BOM 없음), 이상치 CSV는 엑셀 호환을 위해 UTF-8 BOM을 포함한다. 이미지·PDF는 바이너리 형식이다.

4. 법적·윤리적 검토

개인정보 포함 여부	☐ 포함 ☑ 미포함 (자동 점검 기준) 표준데이터의 전화번호는 지자체·단체 문의처이며 휴대전화(01x) 번호와 이메일은 0건이다. 주최·주관·후원은 기관명으로 보이나 개인명 확인은 사람 검토 대기 중이다. 합성 자료는 가상 브랜드·인물이다. 표지 작성자 이름은 보고서 메타데이터다.
포함된 경우 필드	전화번호(기관 문의처), 홈페이지주소, 소재지 주소·좌표(행사 장소). 서울문화포털 포스터 이미지에 개인 얼굴·연락처가 있는지는 수집 후 확인한다.
비식별화 조치 여부	☐ 이름 마스킹 ☐ 고유키 대체 ☑ 기타: 현재 불필요(개인정보 미확인) 서울문화포털 포스터에서 개인정보가 확인되면 마스킹 후 사용한다.
출처 및 사용권 — 공개 여부	☐ 공개 ☑ 내부사용 한정 표준데이터는 공공데이터포털 공개 자료이나 이용허락 범위를 확인하기 전까지 내부 개발용으로 한정한다. 서울문화포털 포스터는 사이트에 저작권 표기가 있어 내부 시험·평가용 소량으로 한정하고 재배포하지 않는다. 합성 자료의 공개 재배포는 확정하지 않았다.
라이선스 / 약관 검토 여부	미완료. 공공데이터포털 페이지는 공공데이터 이용 약관 적용으로만 표기하고 구체 이용허락범위(공공누리 등)는 확인하지 못했다. 서울문화포털 이용약관·robots.txt, OpenAPI 활용 조건·일일 호출 한도도 확인 대기이며, 홈페이지에서 공개 API 안내는 확인하지 못했다. 가상 발주 PDF에 포함한 맑은 고딕의 외부 배포 조건은 미확인이다.
검토자	자료 점검: AI(Claude Code)의 자동·수동 확인. 사람 검토자: 미확인·대기.
검토 일자	2026. 10. 07. (AI 점검 기준일) 사람 검토 완료일: 미확인.

5. 데이터 품질 및 정합성 관리 방안

중복 제거 기준	표준데이터: 행사명·기간·장소가 모두 같은 24건은 1건만 남기고 원본은 보존한다. 행사명(공백 제거)+시작일이 같은 47그룹(99행)은 같은 행사 후보로 묶고, 제공기관·기준일이 다른 레코드는 삭제하지 않고 후보로 보존한다. 이미지는 SHA-256으로 완전 중복을 확인한다.
정합성 검증 방법	필수 필드 존재, 날짜 형식·시작≤종료, 이름의 연도와 시작 연도, 좌표 범위, 전화 지역번호와 개최 지역 대조로 이상치 90행을 목록화했다(시작>종료 2, 연도 불일치 1, 완전 중복 24, 값 충돌 57행 등). 정답 라벨은 JSON Schema와 id 참조·날짜·요일 계산 검사로 확인하며, 일부러 틀린 케이스 15종을 모두 거부했다. 같은 행사의 후보 간 불일치는 사람이 확정한다(예: 김천김밥축제 장소 2곳 vs 3곳).
Null 처리 및 결측치 전략	빈 값은 보완하지 않고 null로 둔다(후원 52.1%, 홈페이지 40.0%, 전화 8.6%, 좌표 17.7%). 포스터에 없는 정보도 null로 명시한다. 표준데이터에는 입장료·운영 시간·프로그램 시간표 필드가 없어 해당 항목은 기준 대조가 불가하며 별도 출처(발주서·행사 홈페이지)가 필요하다.
표준화 전략	UTF-8, 날짜 ISO 8601(YYYY-MM-DD), 좌표는 문자열에서 실수로 변환한다. 행사명의 연도·"제N회"(각 297·327건)와 장소 구분자("+", ",", "일원")를 정규화한 뒤 대조하고, 시도 명칭은 신·구 표기(전남광주통합특별시·전라남도 등)를 매핑한다. 학습·평가 분할은 같은 행사의 레코드·포스터 변형을 한 그룹으로 묶어 나눈다. 현재 자료로 일반화 성능을 주장하지 않는다.

6. 변경 이력 및 보완 내역

변경일	변경자	변경 내용	비고
2026-10-06	총괄·자료 에이전트	현황 확인, 실무자료 접수 목록 및 10월 7일 정오 마감 준비. 기존 합성 광고 6장 별도 집계	접수 미완료
2026-10-06	문서·데이터 에이전트	가상 기준 문서 10건·요청 250문장·광고 12장 제작. 생성 이력·정답·제출 패키지 분리	AI 제작
2026-10-06	자료·품질 에이전트	기준 변경 요청 3상황 수정. 파일·해시·라벨·모호성과 증빙 누락 구분 검토	사람 검토 대기
2026-10-06	총괄 에이전트	HTML·PDF 완성 후, 제공된 Word 예시의 표지·6개 절에 광고 검수 자료를 반영	현재 반영
2026-10-07	Claude Code (AI 초안)	포스터 검수 워크플로우 v3 기준으로 수집 대상을 재정의했다. 이전 방향(광고 납품 검수) 자료는 이번 집계에서 제외	방향 변경 반영
2026-10-07	Claude Code (AI 초안)	전국문화축제표준데이터 1,364건 분석, 이상치 90행·필터링 건수 정리	AI 분석, 사람 검토 대기
2026-10-07	Claude Code (AI 초안)	포스터 검수 스키마 v0.1·검수 항목 16개·예시 2건 작성, 샘플 포스터 1장 OCR 시험	AI 초안
일정 미정	담당자 미확인	서울문화포털 약관·robots.txt 확인 후 샘플 수집, 표준데이터 OpenAPI 활용신청	대기
2026-10-08 예정	담당자 미확인	사람 검토 반영, 최종 점검·제출	제출 예정