SK 네트웍스 Family AI 33기 : 1팀

수집 데이터 보고서

산출물 단계	데이터 수집 및 저장
제출 일자	2026. 10. 08. (제출 예정)
깃허브 경로	https://github.com/20260528-skn-family-ai-33/SKN33-Final-1Team
작성 팀원	최지흠

수집 데이터

1. 수집 데이터 개요

- 2026년 10월 7일 기준, 포스터 검수 워크플로우(v3: 정보 검수·시각 검수 에이전트, MCP 기반)에 쓸 개발용 자료를 정리
- 전국문화축제표준데이터 1,364건과 샘플 포스터 1장(김천김밥축제)을 확보
- 서울문화포털·문화포털은 API 호출로 행사 정보와 포스터를 가져올 수 있어, 서비스키 발급 후 팀원당 20개씩 총 100개를 수집 예정.

데이터명	수집 대상	수집 목적	사용 예정 기능	출처 / 저작권
전국문화축제표준데이터	전국 문화축제 1,364건(18필드): 행사명·기간·장소·주최·연락처·주소·좌표	행사명·일시·장소·연락처의 공식 기준 정보 확보	근거 검색, 날짜 비교(정보 검수 에이전트)	공공데이터포털(15013104), 한국관광공사·지자체 제공. JSON 내려받기 완료. 이용허락 확인(예정)
샘플 포스터 (김천김밥축제)	포스터 1장(800×1131 WEBP). 검수 요소 38개 라벨 초안	OCR·요소 추출 시험	OCR 시험, 정답 라벨 작성	제공받은 이미지. 문화포털에서 조회되는 행사. 출처 URL·권리 확인(예정), 내부 시험용
문화행사 공개 API (서울문화포털·문화포털)	두 포털의 API로 행사·축제 정보와 포스터 호출(예정). 상세 각 1건으로 접근·포스터 확인함	포스터와 이용요금·공연시간 등 기준 메타 확보. 사이트·분류는 정하지 않고 API로 수집(예정)	OCR·시각 검수 입력, 기준(reference) 구성, 정답 라벨 작성	서울: 서울시 문화행사 정보(OA-15486), 공공누리 1유형. 문화포털: 한눈에보는문화정보(15138937), 이용허락범위 제한 없음 표기. 서비스키 발급 후 호출(예정)
추후 수집 계획	포스터 100개: 팀원당 20개 × 5명(예정)	입력·기대 출력 데이터셋 구축, 모델 비교 평가(예정)	검수 에이전트 개발·평가(예정)	두 API 호출로 수집(예정). 분담·권리 확인 방식은 추후 결정(예정)

2. 수집 방법 및 자동화 절차

2.1 수집 방식 (해당 항목에 체크)

수집 방식	선택	수집 방식	선택
웹 크롤링	☐	외부 API 직접 호출	☑
사용자 입력 자료 접수	☑	팀 문서 파일 업로드	☐
기타:	☐	기존 시연 자료 확인	☐

2.2 사용 기술 및 자동화 절차

사용 언어 / 라이브러리	수집·집계: Python 3.12(json, csv, collections, datetime), 이미지 확인 Pillow 사용함 API: data.go.kr 서비스키(표준데이터·문화포털), 서울 열린데이터광장 인증키(서울시 문화행사 정보)를 발급받아 호출함(예정) OCR: RapidOCR(PP-OCRv5 한국어, ONNX CPU) 사용함 상세 페이지 조회와 포스터 내려받기는 가능 여부 확인에만 썼고, 수집은 크롤링 대신 API로 함(예정)
자동화 여부 및 주기	현재: 표준데이터 JSON을 1회 내려받아 분석함(원천 갱신 주기: 분기) 예정: 서울시 문화행사 정보(매일 갱신)와 문화포털 API(개발계정 일 10,000건 표기)로 팀원당 20개씩 총 100개를 수집함(예정). 정기 수집은 하지 않음 현황: 표준데이터는 파일로 확보했고 API는 서비스키 발급 전임. 웹 크롤링은 하지 않으며, 사용자 입력 자료로 김천김밥축제 포스터 1장을 접수함
오류 발생 시 예외 처리 전략	API: 오류 코드(22 호출 한도 초과, 31 키 만료, 32 미등록 IP 등)를 확인하고, 실패 시 재시도 후 원본 응답을 보존함. 일일 한도 안에서 나눠 호출함(예정) 파일: 레코드·필드 수와 UTF-8 디코딩을 확인함. 이상치는 삭제하지 않고 목록(CSV)에 기록함 권리·약관이 확인되지 않은 자료는 사용 승인 전까지 보류함

2.3 예시 스크립트 또는 흐름도 첨부

[수집 및 저장 흐름]

1) 기준 데이터 확보: 전국문화축제표준데이터(15013104) JSON 내려받기 → 1,364건·18필드 확인 (완료)

2) 품질 점검: 날짜 형식·순서, 중복, 같은 행사 값 충돌, 좌표·연락처 형식 → 이상치 90행 목록화 (완료)

3) 샘플 포스터: 김천김밥축제 1장 확보. 서울문화포털(서울어텀페스타)·문화포털(대한민국국악관현악축제) 상세 각 1건으로 접근·포스터·OCR 판독 가능 여부 확인 (완료)

4) 요소 추출·라벨 초안: OCR로 글자·좌표를 추출하고 검수 요소 JSON 작성 (김천김밥축제 1장, 완료)

5) 기준 연결: 표준데이터와 두 API의 행사명·기간·장소·이용요금·공연시간을 기준 메타로 연결하고, 후보가 여럿이면 출처·기준일을 함께 보존 (설계 중, 예정)

6) 보존: 원본·출처·기준일 분리 보관 (예정, 저장소 반영 후)

7) 확대: 두 API 호출로 팀원당 20개씩 총 100개 수집 (예정, 서비스키 발급 후)

아키텍처 연결(제안, 예정): 표준데이터·API 메타 = 근거 검색 Tool 대상, 수집 포스터 = 입력 포스터, 발주서·승인 문안 = Resources(고정 기준)

3. 데이터 설명 및 구성

3.1 파일 및 필드 설명

파일명 / 테이블명	필드명	데이터 타입	설명	예시
전국문화축제 표준데이터.json	fields[].id / records[]	string / object (1,364개)	필드 정의 18개 / 레코드 1개 = 축제 1건(값은 모두 문자열)	축제명 / {"축제명": "김천김밥축제", ...}
전국문화축제 표준데이터.json	축제명 / 개최장소	string	행사명·장소(여러 곳은 "+"로 연결)	김천김밥축제 / 직지문화공원+사명대사공원+친환경생태공원
전국문화축제 표준데이터.json	축제시작일자 / 축제종료일자	string (YYYY-MM-DD)	개최 기간	2026-10-23 / 2026-10-25
전국문화축제 표준데이터.json	축제내용	string	프로그램 요약	로컬 및 8도김밥 판매+공연+체험프로그램 운영 등
전국문화축제 표준데이터.json	주최기관명 / 주관기관명 / 후원기관명	string	기관명(후원은 52.1% 비어 있음)	경상북도 김천시청
전국문화축제 표준데이터.json	전화번호 / 홈페이지주소	string	문의처(각 8.6%·40.0% 비어 있음)	054-420-6714 / https://gimbapcity.kr/main/main.html
전국문화축제 표준데이터.json	소재지도로명주소 / 소재지지번주소 / 위도 / 경도	string	위치(좌표 17.7% 비어 있음)	경상북도 김천시 대항면 직지사길 130 / 36.117093 / 128.0081803
전국문화축제 표준데이터.json	데이터기준일자 / 제공기관코드 / 제공기관명 / 관련정보	string	갱신 기준일·제공기관(포털 안내 15필드 외 3개), 관련정보(88.9% 비어 있음)	2026-09-03 / 경상북도 김천시
posters/* (샘플 1장, 추후 수집 예정)	픽셀 / 크기	WEBP·GIF·JPEG·PNG / integer	입력 포스터 이미지	800×1131 (김천김밥축제)

파일명 / 테이블명	필드명	데이터 타입	설명	예시
서울시 문화행사 정보 (서울문화포털 API)	대표이미지(MAIN_IMG) / 행사명(TITLE) / 시작·종료일(STRTDATE, END_DATE) / 장소(PLACE) / 이용요금(USE_FEE) / 유무료(IS_FREE)	string	행사 메타. 필드명은 키 발급 후 확정(예정). 확인 샘플: cultcode-159120.sample.json	2026-09-18~2026-11-29 / 각 공연·축제별 상이
문화포털 상세 (문화포털 API)	제목 / 장르 / 기간 / 공연시간 / 가격 / 장소 / 소요시간 / 연령 / 주최 / 문의 / 포스터 URL	string	공연·전시 1건의 메타. 필드명은 키 발급 후 확정(예정). 확인 샘플: pblprfr-397760.sample.json	2026-10-09~2026-10-09 / 금요일(17:00) / 전석 10,000원
이상치_목록.csv	분류 / 레코드번호 / 축제명 / 사유	string	표준데이터 이상치 90행	날짜 순서 오류 / 1198 / 여수밤바다 불꽃축제

3.2 데이터 양

전체 수집 데이터 건수	표준데이터 1,364건(18필드·24,552개 값, JSON 약 1.0MB). 지자체 1,299건·한국관광공사 65건 제공. 2026년 시작 798건, 기준일(2026-10-07) 진행 43건·예정 217건 샘플 포스터 1장(김천김밥축제, 검수 요소 38개 라벨 초안). 서울문화포털·문화포털은 상세 각 1건으로 가능 여부만 확인함(수집 0건) 추후 목표: 팀원당 20개씩 총 100개(예정)
추출된 고품질 데이터 건수 (필터링 후 기준)	표준데이터 자동 필터: 필수 5항목(행사명·장소·시작·종료·주최) 존재 1,364건 → 날짜 순서 정상 1,362건 → 완전 중복 제거 1,338건. 같은 행사 값 충돌 후보 54건을 빼면 1,284건 진행·예정 행사 중 필터 통과 256건(전화 또는 URL 있음 231건) 사람 검토 통과: 0건(예정). 라벨 초안은 AI가 작성했고 사람 검토 전. 학습·성능 평가(예정)

3.3 저장 위치 및 포맷

저장 경로	저장소: SKN33-Final-1Team (표지 GitHub 경로). 아래 자료는 현재 로컬에 있고 저장소 반영 전 표준데이터 JSON: data/collection/raw/public/culture-festival/ (예정) 샘플 포스터: data/collection/raw/posters/ (예정, 권리 확인 후 반영)
저장 포맷	☑ CSV ☑ JSON ☐ SQLite ☑ 기타: WEBP·PNG(이미지) 표준데이터는 JSON, 이상치 목록은 CSV, 포스터는 이미지 파일
인코딩	☑ UTF-8 ☐ 기타 JSON·CSV는 UTF-8(이상치 CSV는 엑셀 호환용 BOM 포함), 이미지는 바이너리

4. 법적·윤리적 검토

개인정보 포함 여부	☐ 포함 ☑ 미포함 (자동 점검 기준) 표준데이터의 전화번호는 지자체·단체 문의처이고 휴대전화 번호와 이메일은 없음. 샘플 포스터에는 실존 인물 사진이 없음. 개인명 확인은 사람 검토 후 확정함(예정). 표지 작성자 이름은 보고서 메타데이터임
포함된 경우 필드	전화번호(기관 문의처), 홈페이지주소, 소재지 주소·좌표(행사 장소) 포털 포스터에는 출연자 사진·연락처가 포함될 수 있어 수집 후 확인(예정)
비식별화 조치 여부	☐ 이름 마스킹 ☐ 고유키 대체 ☑ 기타: 현재 불필요 수집한 포스터에서 개인정보가 확인되면 마스킹 후 사용
출처 및 사용권 — 공개 여부	☐ 공개 ☑ 내부사용 한정 표준데이터는 이용허락 범위를 확인할 때까지 내부 개발용으로 한정. 서울시 문화행사 정보는 공공누리 1유형(출처표시, 상업적 이용·변경 가능) 문화포털 API는 이용허락범위 제한 없음으로 표기돼 있으나, 문화포털 이용약관은 무승낙 복제·제공과 영리행위를 제한. 포스터 이미지는 제공기관 저작물로 보여 내부 시험·평가용으로만 쓰고, 재배포하지 않으며 권리 확인 전에는 저장소에 올리지 않음
라이선스 / 약관 검토 여부	확인 전. 표준데이터의 구체 이용허락범위(공공누리 등) 확인(예정) 문화포털 이용약관과 robots.txt(/portal/search만 금지)를 확인 서울문화포털 robots.txt는 행사 목록·상세경로(/culture/culture/)를 허용 API 응답 필드·호출 한도·포스터 권리는 서비스키 발급 후 확인함(예정)
검토자	사람 검토자는 지정 후 기재함(예정)
검토 일자	사람 검토일은 검토 후 기재함(예정)

5. 데이터 품질 및 정합성 관리 방안

중복 제거 기준	표준데이터: 행사명·기간·장소가 모두 같은 24건은 1건만 남기고 원본은 보존 행사명(공백 제거)+시작일이 같은 47그룹(99행)은 같은 행사 후보로 묶고, 제공기관·기준일이 다른 레코드는 삭제하지 않음 이미지는 SHA-256으로 완전 중복을 확인(예정)
정합성 검증 방법	필수 필드, 날짜 형식·순서, 이름과 시작일의 연도, 좌표 범위, 전화 지역번호와 개최 지역을 대조해 이상치 90행을 목록화(시작일>종료일 2, 연도 불일치 1, 완전 중복 24, 값 충돌 57행 등) 같은 행사의 후보 간 불일치는 사람이 확정함(예정). 예: 김천김밥축제 장소 2곳 vs 3곳
Null 처리 및 결측치 전략	빈 값은 보완하지 않고 null로 변경(후원 52.1%, 홈페이지 40.0%, 전화 8.6%, 좌표 17.7%). 포스터에 없는 정보도 null로 명시함 표준데이터에는 입장료·운영 시간·시간표 필드가 없음. 입장료·시간은 두 API의 이용요금·공연시간으로 보완하고(예정), 시간표는 발주서·행사 홈페이지를 따름
표준화 전략	UTF-8, 날짜 ISO 8601(YYYY-MM-DD) 사용. 좌표는 문자열에서 실수로 변환함. 행사명의 연도·"제N회"와 장소 구분자("+", ",", "일원")를 정규화한 뒤 대조하고, 시도 명칭은 신·구 표기(전남광주통합특별시·전라남도 등)를 매핑 (예정) 학습·평가 분할은 같은 행사의 레코드·포스터를 한 그룹으로 묶음(예정).

6. 변경 이력 및 보완 내역

변경일	변경자	변경 내용	비고
2026-10-06	최지흠	현황 확인, 실무자료 접수 목록 및 10월 7일 정오 마감 준비. 기존 합성 광고 6장 별도 집계	접수 미완료
2026-10-06	최지흠	가상 기준 문서 10건·요청 250문장·광고 12장 제작. 생성 이력·정답·제출 패키지 분리	AI 제작
2026-10-06	최지흠	기준 변경 요청 3상황 수정. 파일·해시·라벨·모호성과 증빙 누락 구분 검토	사람 검토 대기
2026-10-06	최지흠	HTML·PDF 완성 후, 제공된 Word 예시의 표지·6개 절에 광고 검수 자료를 반영	현재 반영
2026-10-07	김성훈	포스터 검수 워크플로우 v3 기준으로 수집 대상 재정의. 샘플 1건(김천김밥축제)·추후 100개 목표 반영	방향 변경 반영
2026-10-07	김성훈	표준데이터 1,364건 분석(이상치 90행), 포스터 3장 OCR 시험	AI 분석, 사람 검토(예정)
2026-10-07	김성훈	수집 방식을 서울문화포털·문화포털 API 호출로 정리. robots.txt·이용조건·상세 각 1건 확인	수집 방식 정리
2026-10-08 예정		서비스키·인증키 발급 후 수집 시작, API 응답 필드·seq 일치 확인(예정)	예정
2026-10-08 예정		사람 검토 반영, 최종 점검·제출(예정)	제출 예정