표지

데이터 수집 및 저장

수집 데이터 보고서

광고 납품 검수 · 합성 개발 자료 추가 수집

기수	SKN33 33기
팀	1팀
단계	데이터 수집 및 저장
제출일	2026-10-08 제출 예정 · 2026-10-06 작성 스냅샷
GitHub	https://github.com/20260528-skn-family-ai-33/SKN33-Final-1Team
작성 팀원	SKN33 1팀 · AI 작성 보조(실명 미확인)

> **현재 자료의 성격**
> 추가분은 자체 제작한 합성 자료이다. 실제 팀 보유 자료는 미제공·확인 대기 상태이며, 팀에 자료가 없다고 판단한 것은 아니다. 사람 승인과 권리 검토는 미실행이다.

1. 데이터 수집 개요

프로젝트명

다중 에이전트 협업 기반 광고 납품 검수 시스템 · SKN33 1팀

수집 대상

유형	추가분	단위·관계
기준문서	10개	3브랜드 × 3종 + 공통 FAQ 1개
업무 요청	250건	1개 JSONL · 50상황 그룹 × 5표현
광고 이미지	12개	3신규 합성 원본 그룹 · 편집본 포함
기존 이미지	6개	1원본 그룹 · 추가분에서 제외

수집 목적

발주 조건을 참조하는 검수 흐름, 요청 의도 분류, 광고 문자·조건 비교, 근거 누락 시 추가 자료 요청 기능을 개발·시연하기 위해 자료를 확보한다. 독립 일반화 성능을 증명하는 수집은 아니다.

활용 기능

자료	연결 기능
의뢰서·가이드·체크리스트	기준 검색·참조(RAG)와 항목별 조건 비교
요청 문장	신규 검수·재검수·기준 변경·상태 조회·기타의 라우팅 개발
광고 원본·편집본	OCR·시각 확인, 불일치·모호·증빙부족 대응 개발

데이터 출처 및 저작권

문서와 요청은 AI 작성 초안을 Python으로 구성·저장했다. 이미지는 내장 image_gen으로 원본 3개를 별도 생성하고 같은 그룹 내에서 편집했다. 외부 문서·웹 크롤링 자료는 추가 수집하지 않았다. 브랜드 및 제작물 권리는 미검토이며 프로젝트 내부 개발용 사용 조건만 기록한다.

> 실제 팀 자료 접수 계획: 2026-10-07 12:00 KST까지. 접수·권리 확인·재집계는 현재 완료되지 않았다.

2. 데이터 수집 방법

수집 방식

☐ 웹 크롤링 ☐ 외부 API ☐ 파일 업로드 완료 ☐ 수작업 외부 수집 ☑ **기타: 자체 합성 제작**

실제 팀 파일 업로드는 향후 접수 계획이다. 현재 추가분을 외부 실무 수집 자료로 분류하지 않는다.

사용 언어 및 라이브러리

도구	실제 수행	제한
Python 표준 라이브러리	문서·요청 저장, JSON/CSV, 해시·집계	생성 스크립트의 모델 API 직접 호출 없음
Pillow	이미지 파일 열기·규격 점검	원본 광고 수정 없음
내장 image_gen	별도 원본 생성 및 그룹 내 이미지 편집	모델 revision은 도구가 미제공
AI 작성 보조	규칙·업무 상황 및 표현 초안 작성	정확한 모델 버전 미확인

자동화 여부 및 수집 주기

이번 수집은 2026-10-06에 실행한 일회성 합성 제작이다. 문서·요청은 재실행 가능한 Python 스크립트로 저장하며 이미지 제작은 프롬프트·부모 원본·생성 기록을 보존한다. 주기적 자동 수집과 외부 API 연동은 운영하지 않는다.

예외 처리

파일 손상·JSON 파싱 오류·빈 필드·중복 ID·누락 시나리오·원본 연결 오류·해시 불일치는 검증 기록에 실패 또는 대기로 남긴다. 제작 의도와 실제 관찰을 구분하고, 가독성·적용 범위가 모호하거나 제작 근거가 누락되면 사람 검토 대기로 유지한다.

수집 스크립트 및 흐름

공유 조건 → 문서·요청 생성 / image_gen 원본·편집 → 출처 로그 → 파일 inventory·summary → 품질 검증 → HTML/PDF 보고서.

```
python3 scripts/generate_documents.py
python3 scripts/generate_requests.py
python3 data/collection/scripts/build_collection.py
python3 data/collection/scripts/validate_collection.py
```

이미지 생성은 Python 스크립트가 재호출하지 않는다. 같은 프롬프트로 재생성해도 동일 픽셀을 보장하지 않는다. 생성 로그의 시각은 도구 결과 등록 또는 Python 조립·저장 시각이며, 미노출 제공자 생성시각은 단정하지 않는다.

3. 데이터 설명 및 구성 · 필드사전

파일·필드명·타입·설명·예시

파일	필드	타입	설명	예시
Markdown 문서	본문 / 제목	text	발주 조건·가이드·체크리스트	FABLE CUP / 25% 할인
문서 제작 로그	document_id / group_id	string	문서와 원본 그룹 연결	SYN-DOC-01-BRIEF / SYN-AD-01
문서 제작 로그	path / sha256 / bytes	string / string / int	원문 위치·무결성·크기	raw/synthetic/documents/…
요청 원자료	request_id / text	string	요청 ID와 실제 문장	REQ-0001 / 광고 검사 요청
요청 원자료	request_group_id	string	같은 업무 상황의 표현 변형 그룹	REQ-G-001
요청 원자료	case_group_id / project_id	string	광고 원본 그룹·가상 발주 연결	SYN-AD-01 / SYN-ORDER-01
요청 원자료	synthetic / source_method	bool / string	합성 표시·작성 방법	true / AI 작성 + Python
요청 원자료	created_at	ISO datetime	저장·생성 기록 시각	2026-10-06…+09:00
별도 라벨 증빙	intent_label / human_review_status	string	5종 의도의 AI 초안과 사람 상태	new_inspection / pending
이미지 원자료	PNG pixels	RGB/RGBA bitmap	광고의 실제 시각 내용	1254×1254 px
이미지 제작 로그	asset_id / parent_asset_id	string / nullable	신규 원본·편집본 관계	SYN-AD-01-mismatch → normal
이미지 제작 로그	prompt_path / operation	string	생성 근거·동작	evidence/prompts/… / edit
파일 inventory	path / asset_type / sha256	string	파일 단위 분류·위치·해시	inventory.csv의 실제 행

AI 초안 의도 구성: 신규 검수 50건 · 재검수 50건 · 기준 변경 50건 · 상태 조회 50건 · 기타 50건. 모든 라벨은 사람 검토 대기이다.

> 요청 원문에는 정답 의도를 내장하지 않는다. AI 초안 라벨은 `evidence/request-labels.jsonl`로 분리한다. 문서는 판단 규칙이며 이미지별 정답표가 아니다.

필드사전의 파일 경로는 프로젝트 기준 상대경로이다. 자세한 파일별 크기·해시·출처·검토 상태는 inventory와 생성 로그에서 연결한다.

3. 데이터 설명 및 구성 · 현황·저장

전체 데이터 건수

원자료 파일은 신규 23개 + 기존 6개 = 총 **29개**이다. 신규 요청 250건은 JSONL 1파일이며, 파일 수와 레코드 수를 합산하지 않는다. 제작 로그·관찰·라벨은 보조 증빙으로 별도 관리한다. inventory는 현재 29행이다.

집계 유형	실측 bytes
document	49,091
requests	129,075
image	22,317,536

필터링 후 고품질 데이터

AI 기본 점검과 사람이 확정한 고품질 자료를 구분한다. 현재 사람 승인 자료는 **0개**이며 학습·평가 준비 완료 수량으로 집계하지 않는다. 품질 점검 통과 건수는 5절의 검증 기록이다.

저장 경로·포맷·인코딩

대상	프로젝트 상대경로	형식
문서	data/collection/raw/synthetic/documents/	Markdown · UTF-8
요청	data/collection/raw/synthetic/requests/requests.jsonl	JSONL · UTF-8
신규 이미지	data/collection/raw/synthetic/images/	PNG · 1254×1254 px
기존 이미지	data/samples/	PNG · 별도 기존분
제작·검토 근거	data/collection/evidence/	JSON / JSONL / TXT · UTF-8
파일별 목록·집계	data/collection/inventory.csv / summary.json	CSV / JSON · UTF-8

무결성 표본과 패키지 연결

원자료 상대경로	SHA-256
data/collection/raw/synthetic/documents/syn-ad-01-brief.md	`29f0d9bd290fbe3e3d42b78488c9788c09546c934e50bb971beaf7591c03983b`
data/collection/raw/synthetic/documents/syn-ad-01-guide.md	`4e7736a568e0e4fc4bd1011348dc37a3a8bb6588169a54497d379cabba3d6403`
data/collection/raw/synthetic/documents/syn-ad-01-checklist.md	`25cc9d6cbbe63c6fc3a96ec189bc3b982abe72a50195f50e4942aa08e06d5304`

4. 법적·윤리적 고려사항

개인정보 포함 여부

합성 문서·요청의 자동 패턴 점검과 AI 표본 확인에서 개인정보를 발견하지 않았다. 자동 점검은 개인정보 부재를 보증하지 않으며 사람 확인은 미완료이다. 팀 보유 실무 자료는 아직 제공되지 않아 개인정보·권리 상태를 판단하지 않았다.

비식별 처리

현재 합성 원자료에는 실제 고객 이름·연락처를 넣지 않았다. 실제 팀 자료 접수 시 원문을 비공개 보관하고 작업 사본에서 불필요한 이름·전화·메일을 제거한 뒤 변환 근거를 남길 계획이다. 실제 자료의 비식별 실행을 완료했다고 표시하지 않는다.

공개 및 내부 자료 여부

추가분은 프로젝트 내부 개발·시연을 위한 합성 자료이다. 보고서·원문·생성 이미지의 공개 재배포나 외부 제출·공유 작업은 이 제작 범위에서 수행하지 않았다. 실제 팀 원문은 `.runtime/collection-team-input/`에서 비공개로 접수하며 Git 포함을 금지한다.

라이선스·사용 조건 확인

브랜드 이름과 생성 이미지의 권리, 외부 재배포·상업 사용 조건은 사람에게 검토되지 않았다. 합성 생성 또는 AI 점검을 공개 라이선스·사용 허가로 해석하지 않는다. 권리 상태는 **미검토(not_reviewed)**이고 내부 개발용 제한을 기록했다.

검토자

AI 문서 작성·후속 검토: report_requirements 역할. 작성자와 분리한 AI 품질 검토: quality_evidence 역할. 실제 검토자의 실명 및 사람 승인 담당자는 미확인이다. AI 역할 식별은 사람의 서명·승인을 대체하지 않는다.

검토 일자

2026-10-06 AI 점검 스냅샷. 사람 개인정보·권리 검토 일자: 미실행. 실제 증빙의 실행시각을 보존하며 승인 일자를 임의로 채우지 않는다.

5. 데이터 품질 검토

> **검증 상태: 추가 확인 대기**
> 통과 331 · 실패 0 · 대기 1개 점검. 이는 검사 항목 수이며 고품질 자료 수가 아니다.

추가 목표	실제 집계	판정 기준
기준문서 10개	10개	유형·조건·출처·해시
요청 250건 / 50그룹	250건 / 50그룹	유일 ID·문장·그룹·라벨 연결
이미지 12개 / 신규 원본 3그룹	12개 / 3그룹	정상·불일치·모호·증빙부족 의도
사람 확정 고품질 자료	0개	사람 승인 미실행

중복 검사

요청 ID·문장의 유일성과 파일 SHA-256의 동일 바이트 중복을 점검한다. 같은 상황의 표현 변형 5개는 독립 상황으로 세지 않는다. 정확 해시 중복이 없어도 지각적 유사성이나 내용 다양성이 충분하다고 결론 내리지 않는다.

정합성 검사

문서 브랜드·상품·할인·가상 표시와 공유 조건을 대조한다. 요청의 50상황 그룹·250표현 및 별도 라벨 연결, 이미지 원본·편집 관계와 제작 로그 해시를 확인한다. 제작 의도·AI 관찰·사람 확인을 구분한다.

결측 및 오류 처리

필수 ID·텍스트·경로·출처·해시·원본 연결 누락과 파일 파싱 오류를 기록한다. 증빙부족은 3개 제출 패키지에서 제작 근거 제출을 의도적으로 생략한 통제 시나리오이다. 전체 이미지 제작 로그는 보존되며, 광고 픽셀 오류나 전역 로그 유실을 뜻하지 않는다. 사람 승인·권리 확인은 미완료로 유지한다.

표준화 방식

문서·요청·증빙은 UTF-8, JSON/JSONL/CSV 및 안정적인 자료 ID로 관리한다. ISO 시각의 시간대와 원문을 보존하고 보고서에서는 KST 기준 날짜를 사용한다. 원문 광고의 픽셀은 보고서 제작 과정에서 수정하지 않는다.

독립 AI 검토 기록 3개. 최신 집계와 검증 대상 수량이 일치한다. 요청은 반복적인 표현 틀의 단서가 강하며, 원본 3그룹은 합성 자료이다. 학습·독립 성능 평가·일반화 검증은 수행하지 않았다.

6. 변경 이력 및 근거 패키지

데이터 변경 이력

보고서 버전 1.0 · 합성 제작 및 AI 점검 스냅샷. 변경자는 실제 AI 역할로 식별하며 사람 실명·승인은 미확인이다.

일자	변경 내용	변경자	상태·근거
2026-10-06	공유 합성 기준 작성	AI 총괄	case-specs.json · 사람 승인 대기
2026-10-06	문서10·요청250 생성	AI 문서·요청 작성	생성 스크립트·제작 로그
2026-10-06	원본3그룹·광고12 제작	AI 총괄	image_gen 원본/편집
2026-10-06	3상황 요청 수정: 고지 최소24px·편집 전후SHA·브랜드1회	AI 요청 작성·품질 검토	독립 AI 의미 검토 후 수정
2026-10-06	모호 규칙에 할인 적용 대상·범위 불명확 추가	AI 문서 작성·품질 검토	문서·제작 로그 해시 갱신
2026-10-06	파일목록·품질·보고서 작성	AI 총괄·문서·품질 역할	inventory·summary·quality-review
2026-10-07 12:00 KST	실제 팀 자료 접수 목표	담당 사람 미확인	계획 · 미완료
2026-10-08	보고서 제출	담당 사람 미확인	예정 · 실제 제출 미실행

기준 양식과 누락 확인

공식 양식의 표지, 수집 개요, 수집 방법, 데이터 구성, 법·윤리, 품질, 변경 이력을 대응했다. 필드별 위치와 근거는 `docs/reports/data-collection/template-field-map.json`에 기록한다.

공식 양식: https://docs.google.com/document/d/1JkpF21eSmv-509OQK14vYRk5wqiu5yHr/edit

패키지에서 확인할 근거

근거	역할
data/collection/inventory.csv / summary.json	29파일 행과 유형별 수량·크기 집계의 기준
data/collection/evidence/*-production.jsonl	문서·요청·이미지의 출처·도구·시각·해시
data/collection/evidence/request-labels.jsonl	사람 미검토 의도 초안; 요청 원자료와 분리
data/collection/evidence/image-observations.json	실제 시각 관찰과 생성 의도의 분리
data/collection/evidence/submission-packages.jsonl	개별 제출 패키지의 통제된 근거 생략
data/collection/evidence/quality-review.json	기본 검증·독립 AI 검토·사람 승인 대기
data/collection/README-team-intake.md	실제 팀 자료 접수 계획 및 비공개 처리

> 이 문서의 완료는 합성 원자료와 보고서 패키지 제작의 완료이다. 사람 승인, 실제 팀 자료 확인, 권리 검토, 학습·평가 및 실제 제출 완료를 의미하지 않는다.

부록 · SYN-AD-01 광고 원자료

FABLE CUP · 바닐라라떼 · 기준 할인 25%

새로 생성한 합성 원본 1개와 같은 원본의 편집 파생본 3개이다. 아래 표시는 제작 의도이며 사람 확정 정답이 아니다.

정상 조건 제작 의도
SYN-AD-01-normal
SHA-256 앞16: 14f6eaf28ec840fc

불일치 조건 제작 의도
SYN-AD-01-mismatch
SHA-256 앞16: c9f08152d75ed816

할인 적용범위 모호 의도
SYN-AD-01-ambiguous
SHA-256 앞16: ee82945c4eae480f

제출 패키지 증빙부족 의도
SYN-AD-01-missing_evidence
SHA-256 앞16: 1917e717978ba0fd

원자료: `data/collection/raw/synthetic/images/`
전체 해시·부모 관계: image-production.jsonl 및 inventory.csv.
모호함은 할인 적용범위의 의미 모호 사례이다. 증빙부족은 개별 제출 패키지의 근거 생략이며 전체 제작 로그는 보존한다. AI 시각 관찰 초안이며 OCR 자동 실행 결과나 사람 확정 정답이 아니다.

부록 · SYN-AD-02 광고 원자료

MOSS CUP · 말차라떼 · 기준 할인 15%

새로 생성한 합성 원본 1개와 같은 원본의 편집 파생본 3개이다. 아래 표시는 제작 의도이며 사람 확정 정답이 아니다.

정상 조건 제작 의도
SYN-AD-02-normal
SHA-256 앞16: db7e14a77facf07e

불일치 조건 제작 의도
SYN-AD-02-mismatch
SHA-256 앞16: 92a191844b4bb2b4

할인 적용범위 모호 의도
SYN-AD-02-ambiguous
SHA-256 앞16: b181476e7dfdcd0a

제출 패키지 증빙부족 의도
SYN-AD-02-missing_evidence
SHA-256 앞16: 4bb38d9f5afc77a9

원자료: `data/collection/raw/synthetic/images/`
전체 해시·부모 관계: image-production.jsonl 및 inventory.csv.
모호함은 할인 적용범위의 의미 모호 사례이다. 증빙부족은 개별 제출 패키지의 근거 생략이며 전체 제작 로그는 보존한다. AI 시각 관찰 초안이며 OCR 자동 실행 결과나 사람 확정 정답이 아니다.

부록 · SYN-AD-03 광고 원자료

SUNNY SIP · 레몬에이드 · 기준 할인 20%

새로 생성한 합성 원본 1개와 같은 원본의 편집 파생본 3개이다. 아래 표시는 제작 의도이며 사람 확정 정답이 아니다.

정상 조건 제작 의도
SYN-AD-03-normal
SHA-256 앞16: 429d3811fe5ecb7d

불일치 조건 제작 의도
SYN-AD-03-mismatch
SHA-256 앞16: 0f8bb66e7baf7234

할인 적용범위 모호 의도
SYN-AD-03-ambiguous
SHA-256 앞16: 12cf885741bcd367

제출 패키지 증빙부족 의도
SYN-AD-03-missing_evidence
SHA-256 앞16: 9ed506c2f74abac0

원자료: `data/collection/raw/synthetic/images/`
전체 해시·부모 관계: image-production.jsonl 및 inventory.csv.
모호함은 할인 적용범위의 의미 모호 사례이다. 증빙부족은 개별 제출 패키지의 근거 생략이며 전체 제작 로그는 보존한다. AI 시각 관찰 초안이며 OCR 자동 실행 결과나 사람 확정 정답이 아니다.